

T1

On dispose le modèle linéaire

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Comme ε_i est une variable aléatoire gaussienne centrée de variance $\sigma^2 > 0$, on l'exprime avec la variable y_i et la variable fixe x_i

$$\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i) \sim \mathcal{N}(0, \sigma^2)$$

D'où

$$\frac{\varepsilon_i}{\sigma} = \frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \sim \mathcal{N}(0, 1)$$

$(\varepsilon_i)_{i \geq 1}$ étant indépendantes, $(\frac{\varepsilon_i}{\sigma})_{i \geq 1}$ l'est aussi, donc on a

$$\frac{\varepsilon}{\sigma} = \frac{y - X\beta}{\sigma} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

On obtient ainsi la loi de y

$$y \sim \mathcal{N}(X\beta, \sigma^2 \mathbf{I})$$

Finalement

$$p(y) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\|y - X\beta\|^2}{2\sigma^2}\right)$$

T2

L'estimateur du maximum de vraisemblance

$$\hat{\beta} \in \arg \min_{\beta \in \mathbb{R}^2} \|y - X\beta\|^2$$

Vérifions d'abord que la fonction $\beta \rightarrow \|y - X\beta\|^2$ soit convexe et différentiable sur \mathbb{R}^2 :
 Soit $\beta_1, \beta_2 \in \mathbb{R}^2$, soit $t \in [0, 1]$, alors on a selon l'inégalité triangulaire

$$\|y - X(t\beta_1 + (1-t)\beta_2)\|^2 \leq (|t| \cdot \|y - X\beta_1\| + |1-t| \cdot \|y - X\beta_2\|)^2 \leq t^2 \|y - X\beta_1\|^2 + (1-t)^2 \|y - X\beta_2\|^2$$

Or, on a $t^2 \leq t$ et $(1-t)^2 \leq 1-t$ pour tout $t \in [0, 1]$

$$\|y - X(t\beta_1 + (1-t)\beta_2)\|^2 \leq (|t| \cdot \|y - X\beta_1\| + |1-t| \cdot \|y - X\beta_2\|)^2 \leq t \|y - X\beta_1\|^2 + (1-t) \|y - X\beta_2\|^2$$

Donc cette fonction est convexe.

Puis, on calcule

$$\frac{\partial \|y - X\beta\|^2}{\partial \beta_1} = -X \begin{pmatrix} 1 \\ 0 \end{pmatrix} (y - X\beta)^T - \begin{pmatrix} 0 & 1 \end{pmatrix} X^T (y - X\beta)$$

$$\frac{\partial ||y - X\beta||^2}{\partial \beta_2} = -X \begin{pmatrix} 0 \\ 1 \end{pmatrix} (y - X\beta)^T - \begin{pmatrix} 1 & 0 \end{pmatrix} X^T (y - X\beta)$$

Les deux dérivées partielles soient continues sur R^2 , on sait que cette fonction est différentiable sur R^2 .

Si $\hat{\beta}$ satisfait (4.2), il suffit que

$$\nabla_{\beta} ||y - X\beta||^2(\hat{\beta}) = 0$$

$$\nabla_{\beta} (y - X\beta)^T (y - X\beta)(\hat{\beta}) = 0$$

Ainsi

$$\nabla_{\beta} (y^T y - 2y^T X\beta + X^T X\beta^T \beta) (\hat{\beta}) = 0$$

$$-2y^T X + 2X^T X\hat{\beta} = 0$$

$$X^T X\hat{\beta} = X^T y$$

Ce qui implique que $\text{Im}(X^T X) = \text{Im}(X^T)$, et l'ensemble des solutions $\arg \min_{\beta \in R^2} ||y - X\beta||^2$ est celui du système linéaire :

$$X^T X\hat{\beta} = X^T y$$

où $\hat{\beta} \in R^2$ est l'inconnu.

T3

On a pour tout $1 \leq i \leq n$,

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i = (X\beta)_i + \varepsilon_i$$

Donc, on a bien

$$y = X\beta + \varepsilon$$

Si X et β sont fixés, d'après **T1**,

$$y \sim \mathcal{N}(X\beta, \sigma^2 \mathbf{I})$$

Comme on a $\hat{\beta} = (X^T X)^{-1} X^T y$ et $y = X\beta + \varepsilon$,

$$E[\hat{\beta}] = E[(X^T X)^{-1} X^T (X\beta + \varepsilon)] = E[(X^T X)^{-1} X^T X\beta] + E[(X^T X)^{-1} X^T \varepsilon]$$

Si X et β sont fixés, $E[X\beta] = X\beta$, par construction $E[\varepsilon] = 0$,

$$E[\hat{\beta}] = \underbrace{(X^T X)^{-1} X^T X}_{Id} \beta = \beta$$

On peut dire que l'estimateur $\hat{\beta}$ est non-biaisé.

T4

Remarquons que

$$\begin{aligned}
 \hat{\beta} - \beta &= (X^T X)^{-1} X^T y - \beta \\
 &= (X^T X)^{-1} X^T (X\beta + \epsilon) - \beta \\
 &= (X^T X)^{-1} X^T X\beta + (X^T X)^{-1} X^T \epsilon - \beta \\
 &= \underbrace{(X^T X)^{-1} X^T X}_I \beta + (X^T X)^{-1} X^T \epsilon - \beta \\
 &= (X^T X)^{-1} X^T \epsilon \\
 X(\hat{\beta} - \beta) &= X(X^T X)^{-1} X^T \epsilon
 \end{aligned}$$

On note la matrice $H = X(X^T X)^{-1} X^T$, on vérifie

$$H^2 = X(X^T X)^{-1} X^T X(X^T X)^{-1} X^T = X(X^T X)^{-1} X^T = H$$

$$H^T = (X(X^T X)^{-1} X^T)^T = (X^T)^T ((X^T X)^{-1})^T X^T = X(X^T X)^{-1} X^T = H$$

Donc H est une projection orthogonale dans R^2 sur le sous-espace $\text{Vect}(X)$, engendré par les vecteurs colonnes de X .

Notons $B = H\epsilon$, comme ϵ est un vecteur gaussien dont les éléments sont i.i.d., centrées et de variance $\sigma > 0$, on obtient

$$\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$$

$$B = H\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 H I H^T)$$

Comme $H I H^T = H H = H$,

$$B \sim \mathcal{N}(\mathbf{0}, \sigma^2 H)$$

$$\frac{B}{\sigma} \sim \mathcal{N}(\mathbf{0}, H)$$

Donc, on a

$$\sigma^{-2}(\hat{\beta} - \beta)^T X^T X(\hat{\beta} - \beta) = \sigma^{-2} B^T B = \left\| \frac{B}{\sigma} \right\|^2$$

On montre que

$$\sigma^{-2}(\hat{\beta} - \beta)^T X^T X(\hat{\beta} - \beta) \sim \chi^2(2)$$

Puis,

$$\begin{aligned}
 P(\beta \in \mathcal{E}_\alpha) &= P(\sigma^{-2}(\beta - \hat{\beta})^T X^T X(\beta - \hat{\beta}) \leq q_{\chi^2(2)}(1 - \alpha)) \\
 &= P(\sigma^{-2}(\hat{\beta} - \beta)^T X^T X(\hat{\beta} - \beta) \leq q_{\chi^2(2)}(1 - \alpha))
 \end{aligned}$$

Selon la définition du quantile, en notant $F_{\chi^2(2)}$ la fonction de répartition d'une variable aléatoire suivant une loi du Chi² à n degré de liberté, on a

$$q_{\chi^2(2)}(1 - \alpha) = \inf \{x \in R, F_{\chi^2(2)}(x) \geq 1 - \alpha\}$$

Il est immédiat que

$$P(\beta \in \mathcal{E}_\alpha) = 1 - \alpha$$

T5

D'après le calcul on a

$$(X^n)^T X^n = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

et

$$(X^n)^T \varepsilon^n = \begin{pmatrix} \sum_{i=1}^n \varepsilon_i \\ \sum_{i=1}^n x_i \varepsilon_i \end{pmatrix}$$

On sait que $(x_i)_{i \geq 1}$ est une suite de variables i.i.d. et suivent la loi uniforme sur $(0, 1)$, donc intégrables. On a

$$E[x_1] = \frac{1}{2}$$

D'après la loi des grands nombres,

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{2} \text{ p.s.}$$

De même, on peut calculer les espérances :

$$E[x_1^2] = \int_R x^2 I_{[0,1]} dx = \int_0^1 x^2 dx = \frac{1}{3}$$

$$E[\varepsilon_1] = 0$$

$$E[x_1 \varepsilon_1] = E[x_1] E[\varepsilon_1] = 0$$

Puisque $(x_i^2)_{i \geq 1}$, $(\varepsilon_i)_{i \geq 1}$ et $(x_i \varepsilon_i)_{i \geq 1}$ sont aussi i.i.d. et intégrables, appliquons la loi des grands nombres sur chacune de ces suites.

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 = \frac{1}{3} \text{ p.s.}$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \varepsilon_i = 0 \text{ p.s.}$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i \varepsilon_i = 0 \text{ p.s.}$$

Donc,

$$\lim_{n \rightarrow \infty} \frac{1}{n} (X^n)^T X^n = \begin{pmatrix} \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 & \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i \\ \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i & \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 \end{pmatrix} = \begin{pmatrix} 1/3 & 1/2 \\ 1/2 & 1/3 \end{pmatrix} \text{ p.s.}$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} (X^n)^T \varepsilon^n = \begin{pmatrix} \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \varepsilon_i \\ \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i \varepsilon_i \end{pmatrix} = \mathbf{0} \text{ p.s.}$$

Puis, comme la matrice $(X^n)^T X^n$ est inversible, et on a la relation

$$\frac{1}{n} (X^n)^T X^n n ((X^n)^T X^n)^{-1} = n ((X^n)^T X^n)^{-1} \frac{1}{n} (X^n)^T X^n = \mathbf{I}$$

En passant à l'inverse, on obtient

$$\lim_{n \rightarrow \infty} \left(\frac{1}{n} (X^n)^T X^n \right)^{-1} = \lim_{n \rightarrow \infty} n ((X^n)^T X^n)^{-1} = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{pmatrix}^{-1} \text{ p.s.}$$

En les multipliant, on obtient

$$\lim_{n \rightarrow \infty} n((X^n)^T X^n)^{-1} \frac{1}{n} (X^n)^T \varepsilon^n = \lim_{n \rightarrow \infty} ((X^n)^T X^n)^{-1} (X^n)^T \varepsilon^n = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{pmatrix}^{-1} \mathbf{0} = \mathbf{0} \text{ p.s.}$$

Selon **T4**, on a

$$\hat{\beta}^n - \beta = ((X^n)^T X^n)^{-1} (X^n)^T \varepsilon^n$$

Donc

$$\lim_{n \rightarrow \infty} \hat{\beta}^n - \beta = \lim_{n \rightarrow \infty} ((X^n)^T X^n)^{-1} (X^n)^T \varepsilon^n = \mathbf{0} \text{ p.s.}$$

$$\lim_{n \rightarrow \infty} \hat{\beta}^n = \beta \text{ p.s.}$$

T6

Pout tout $1 \leq i \leq n$, on a

$$y_i = \frac{1}{1 + \exp(-\theta_0 - \theta_1 x_i)} + \varepsilon_i$$

$$\varepsilon_i = y_i - \frac{1}{1 + \exp(-\theta_0 - \theta_1 x_i)} = y_i - f(\theta, x_i) \sim \mathcal{N}(0, \sigma^2)$$

Quand les données $(x_i, y_i)_{1 \leq i \leq n}$ sont fixées, $y_i - f(\theta, x_i)$ est une fonction de θ , on peut définir la vraisemblance comme

$$p_i(\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{|y_i - f(\theta, x_i)|^2}{2\sigma^2}\right)$$

qui correspond à la probabilité pour une variable aléatoire gaussienne centrée de variance $\sigma^2 > 0$ d'être égale à $y_i - f(\theta, x_i)$.

Donc la vraisemblance totale vaut

$$p(\theta) = \prod_{i=1}^n p_i(\theta) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n |y_i - f(\theta, x_i)|^2}{2\sigma^2}\right)$$

C'est une fonction décroissante de $\sum_{i=1}^n |y_i - f(\theta, x_i)|^2$, donc on a

$$\arg \max_{\theta \in R^2} p(\theta) = \arg \min_{\theta \in R^2} \sum_{i=1}^n |y_i - f(\theta, x_i)|^2 = \arg \min_{\theta \in R^2} \frac{1}{n} \sum_{i=1}^n |y_i - f(\theta, x_i)|^2$$

Finalement on obtient

$$\hat{\theta} \in \arg \min_{\theta \in R^2} L(\theta)$$

T7

- Tirage avec remplacement

On note m_i le i -ième indice dans I_m avec $1 \leq i \leq m$.

Comme I_m est constitué de m indices tirés de manière indépendante et uniforme dans $\{1, \dots, n\}$, alors pour tout $1 \leq i \leq m$, m_i suit une loi uniforme sur $\{1, \dots, n\}$.

On obtient

$$\forall i \in N^*, i \leq m, E(G_{m_i}) = \frac{1}{n} \sum_{i=1}^n G_i = g(\theta)$$

Donc, on a

$$E(g_m(\theta)) = E\left(\frac{1}{m} \sum_{j \in I_m} G_j\right) = E\left(\frac{1}{m} \sum_{i=1}^m G_{m_i}\right) = \frac{1}{m} \sum_{i=1}^m E(G_{m_i}) = g(\theta)$$

- Tirage sans remplacement

Supposons m donné, pour une tirage avec remplacement, chaque partie de m éléments de l'ensemble $\{1, \dots, n\}$ a une chance de $1/\binom{n}{m}$ d'être tirée.

Notons T_m l'ensemble de tirages possibles, par un dénombrement, on peut déduire que

$$\text{Card}(T_m) = \binom{n}{m}$$

et

$$\forall k \in N^*, k \leq n, \sum_{T \in T_m} I_{k \in T} = \binom{n-1}{m-1}$$

Donc, on a

$$E(g_m(\theta)) = \frac{1}{\binom{n}{m}} \sum_{T \in T_m} \left(\frac{1}{m} \sum_{t \in T} G_t \right)$$

En changeant l'ordre des deux sommes, on obtient

$$E(g_m(\theta)) = \frac{1}{\binom{n}{m} m} \sum_{t=1}^n \sum_{T \in T_m} I_{t \in T} G_t = \frac{1}{\binom{n}{m} m} \sum_{t=1}^n \binom{n-1}{m-1} G_t = \frac{1}{n} \sum_{t=1}^n G_t = g(\theta)$$

T8

On note $g(\theta)_0, g(\theta)_1$ les deux éléments du vecteur colonne $g(\theta)$, puisque l'on a montré dans ****T7**** que

$$\forall i \in N^*, i \leq n, E(G_i) = g(\theta)$$

donc on a

$$E\left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0}\right) = g(\theta)_0$$

$$E\left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1}\right) = g(\theta)_1$$

On écrit $g_m(\theta)$ et $\Sigma(\theta)$ sous forme d'une matrice

$$g_m(\theta) = \frac{1}{m} \sum_{j \in I_m} G_j = \frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \nabla_{\theta} f(\theta, x_j) = \begin{pmatrix} \frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \\ \frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_1} \end{pmatrix}$$

$$\Sigma(\theta) = \frac{1}{n} \sum_{i=1}^n \overline{G_i} \overline{G_i}^T = \frac{1}{n} \sum_{i=1}^n \begin{pmatrix} 2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0 \\ 2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1} - g(\theta)_1 \end{pmatrix} \cdot \begin{pmatrix} 2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0 & 2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1} - g(\theta)_1 \end{pmatrix}$$

On utilise les notations du problème précédent.

- Tirage avec remplacement

On calcule

$$\begin{aligned}\text{Var} \left(\frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right) &= \text{Var} \left(\frac{1}{m} \sum_{i=1}^m 2(f(\theta, x_{m_i}) - y_{m_i}) \frac{\partial f(\theta, x_{m_i})}{\partial \theta_0} \right) \\ &= \frac{1}{m^2} \sum_{i=1}^m E \left((2(f(\theta, x_{m_i}) - y_{m_i}) \frac{\partial f(\theta, x_{m_i})}{\partial \theta_0} - g(\theta)_0)^2 \right)\end{aligned}$$

Pour tout $1 \leq i \leq m$, m_i suit une loi uniforme sur $\{1, \dots, n\}$, donc

$$E((2(f(\theta, x_{m_i}) - y_{m_i}) \frac{\partial f(\theta, x_{m_i})}{\partial \theta_0} - g(\theta)_0)^2) = \sum_{i=1}^n \frac{1}{n} (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0)^2$$

Donc, on a

$$\begin{aligned}(\text{Cov}(g_m(\theta)))_{1,1} &= \text{Var} \left(\frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right) \\ &= \frac{1}{mn} \sum_{i=1}^n (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0)^2 \\ &= \frac{1}{m} (\Sigma(\theta))_{1,1}\end{aligned}$$

Par un raisonnement analogue, on a

$$(\text{Cov}(g_m(\theta)))_{1,2} = \frac{1}{mn} \sum_{i=1}^n (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0) (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1} - g(\theta)_1) = \frac{1}{m} (\Sigma(\theta))_{1,2}$$

$$(\text{Cov}(g_m(\theta)))_{2,1} = \frac{1}{mn} \sum_{i=1}^n (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0) (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1} - g(\theta)_1) = \frac{1}{m} (\Sigma(\theta))_{2,1}$$

$$\begin{aligned}(\text{Cov}(g_m(\theta)))_{2,2} &= \text{Var} \left(\frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_1} \right) \\ &= \frac{1}{mn} \sum_{i=1}^n (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_1} - g(\theta)_1)^2 \\ &= \frac{1}{m} (\Sigma(\theta))_{2,2}\end{aligned}$$

Finalement, on montre que

$$\text{Cov}(g_m(\theta)) = \frac{1}{m} \Sigma(\theta)$$

- Tirage sans remplacement

On calcule

$$\begin{aligned}(\Sigma(\theta))_{1,1} &= \frac{1}{n} \sum_{i=1}^n (2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} - g(\theta)_0)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 - \frac{2}{n} g(\theta)_0 \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) + g^2(\theta)_0\end{aligned}$$

$$\begin{aligned}
&= \frac{1}{n} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 - g^2(\theta)_0 \\
&= \left(\frac{1}{n} - \frac{1}{n^2} \right) \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 - \frac{2}{n^2} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \\
&\quad \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right)
\end{aligned}$$

Et

$$\begin{aligned}
(\text{Cov}(g_m(\theta)))_{1,1} &= \text{Var}\left(\frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right) = E\left(\left(\frac{1}{m} \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} - g^2(\theta)_0\right)\right) \\
&= E\left(g^2(\theta)_0 - \frac{2}{m} g(\theta)_0 \sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} + \frac{1}{m^2} \left(\sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right)^2\right) \\
&= g^2(\theta)_0 - \frac{2}{m} g(\theta)_0 E\left(\sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right) + \frac{1}{m^2} E\left(\left(\sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right)^2\right)
\end{aligned}$$

On a

$$E\left(\sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right) = \sum_{T \in T_m} \frac{1}{\binom{n}{m}} \sum_{t \in T} 2(f(\theta, x_t) - y_t) \frac{\partial f(\theta, x_t)}{\partial \theta_0} = n \frac{\binom{n-1}{m-1}}{\binom{n}{m}} g(\theta)_0 = m g(\theta)_0$$

$$E\left(\left(\sum_{j \in I_m} 2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0}\right)^2\right) = \sum_{T \in T_m} \frac{1}{\binom{n}{m}} \left(\sum_{t \in T} 2(f(\theta, x_t) - y_t) \frac{\partial f(\theta, x_t)}{\partial \theta_0}\right)^2$$

$$\begin{aligned}
&= \frac{\binom{n-1}{m-1}}{\binom{n}{m}} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad + \frac{2\binom{n-2}{m-2}}{\binom{n}{m}} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right)
\end{aligned}$$

$$\begin{aligned}
&= \frac{m}{n} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad + \frac{2m(m-1)}{n(n-1)} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right)
\end{aligned}$$

Donc

$$\begin{aligned}
(\text{Cov}(g_m(\theta)))_{1,1} &= -g^2(\theta)_0 + \frac{1}{mn} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad + \frac{2(m-1)}{mn(n-1)} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right) \\
&= \left(\frac{1}{mn} - \frac{1}{n^2} \right) \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad + \left(\frac{2(m-1)}{mn(n-1)} - \frac{2}{n^2} \right) \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right) \\
&= \frac{n-m}{n^2 m} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad + \frac{2(m-n)}{n^2(n-1)m} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right)
\end{aligned}$$

Par l'équivalence des coefficients, on a

$$\begin{aligned}
&\frac{1}{m} \frac{n-m}{n-1} (\Sigma(\theta))_{1,1} \\
&= \frac{n-m}{n^2 m} \sum_{i=1}^n \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right)^2 \\
&\quad - \frac{2(n-m)}{n^2(n-1)m} \sum_{1 \leq i < j \leq n} \left(2(f(\theta, x_i) - y_i) \frac{\partial f(\theta, x_i)}{\partial \theta_0} \right) \left(2(f(\theta, x_j) - y_j) \frac{\partial f(\theta, x_j)}{\partial \theta_0} \right) \\
&= (\text{Cov}(g_m(\theta)))_{1,1}
\end{aligned}$$

Par un raisonnement similaire, on montre que

$$\frac{1}{m} \frac{n-m}{n-1} (\Sigma(\theta))_{1,2} = (\text{Cov}(g_m(\theta)))_{1,2}$$

$$\frac{1}{m} \frac{n-m}{n-1} (\Sigma(\theta))_{2,1} = (\text{Cov}(g_m(\theta)))_{2,1}$$

$$\frac{1}{m} \frac{n-m}{n-1} (\Sigma(\theta))_{2,2} = (\text{Cov}(g_m(\theta)))_{2,2}$$

Finalement, on obtient

$$\text{Cov}(g_m(\theta)) = \frac{1}{m} \frac{n-m}{n-1} \Sigma(\theta)$$

Puisque $\frac{n-m}{n-1} \leq 1$, la matrice de covariance dans le cas sans remplacement est plus petit en termes, donc il est plus préférable.